

AI Model Research Documentation Sheet (AIRDocS)

Template by Sarah Oberbichler, Version 1 – December 2024 , <https://doi.org/10.5281/zenodo.15046713>

Researcher: Johanna Mauermann

Project: Literaturbesprechungen in historischen Zeitungen. Korpusbildung und Analyse diachroner Entwicklungen mit LLMs und NLP-Methoden.

Research Setup

Research Question

Wie entwickeln sich Literaturrezensionen in der Kölnischen Zeitung im Verlauf des 19. Jahrhunderts? Inwieweit können LLMs Korpusaufbau, -anreicherung und das Auffinden systematischer Muster unterstützen?

Methodology

Zweistufiger LLM-gestützter Workflow: (1) promptbasierte Extraktion von Literaturbesprechungen aus Zeitungen. (2) Strukturierte Anreicherung der verifizierten Rezensionen mit bibliographischen Metadaten und Sentiment-Annotationen.

Dataset

Dataset Purpose

Forschungsdatensatz zur explorativen Analyse historischer Literaturbesprechungen in der Kölnischen Zeitung (1814–1900).

Source Data

Digitalisierte Zeitungsseiten der Kölnischen Zeitung, bereitgestellt über das Deutsche Zeitungsportal der Deutschen Digitalen Bibliothek (DDB).

Source Collection

API-basierter Abruf von Zeitungsseiten mit OCR-Texten und Metadaten (Datum, Seite, Sprache). Vorauswahl über eine Keyword-Liste (u. a. Literatur, Dichter, Roman, Leser, Poesie); Einschluss von Seiten mit mindestens zwei Treffern. Anschließend Zufallssampling von 20 Seiten pro Jahr.

Licensing Information

Die Zeitungstexte der Kölnischen Zeitung (1814–1900) sind gemeinfrei.

Data Fields

page_id, pagenumber, paper_title, provider_ddb_id, provider, zdb_id, publication_date, place_of_distribution, language, thumbnail, pagefulltext, pagename, preview_reference, plainpagefulltext, contains_keywords [Liste mit str: Keywords], year, context_window, reviews, final_dictionaries

Data Size

1.740 Zeitungsseiten; 633 manuell verifizierte Rezensionen.

Languages

Deutsch

Data Splits

-

Dataset Version

Version 1

Personal and Sensitive Information

Es können in den historischen Zeitungen personenbezogenen Daten enthalten sein.

Discussion of Bias

- Sampling-Bias durch Keyword-Vorauswahl (Rezensionen ohne einschlägige Keywords werden systematisch ausgeschlossen).
- Temporal-Bias durch Gleichverteilung der Seiten über alle Jahrgänge (frühe Jahrzehnte mit weniger Rezensionen sind relativ überrepräsentiert).

Data Processing

Input Data

Preprocessing

Bildung von Kontextfenstern von ± 1.000 Zeichen um jedes gefundene Keyword im OCR-Fließtext; keine OCR-Korrektur oder Textvervollständigung.

Ground Truth

Manuell erstellte Ground Truth im XML-Format, analog zur Modellausgabe strukturiert.

Ground Truth Size

Extraktion: 1.740 Seiten (633 Rezensionen). Anreicherung: 20 manuell annotierte Rezensionen.

Output Handling

Output Format

XML-strukturierter Output mit Tags für Extraktionstext (<review>), Begründung (<justification>), Unsicherheitsmarkierung (<human_verification_needed>); für die Aufgabe der Korpusanreicherung Metadaten- und Sentiment-Felder.

Post-processing

Bei Korpusanreicherung: Human-in-the-Loop-Korrektur aller Fälle, bei denen mindestens ein Modell human_verification_needed = true gesetzt hatte (185 Fälle).

Storage

CSV

Model Identification

Model Details

Model Names

GPT OSS 120B; Qwen3 235B

Version / Checkpoint**Access Method**

Lokale Bereitstellung über Uniserver; API des ZDV der Uni Mainz

Provider / Source**Access Date**

04/2026

Model Selection and Rationale

Einsatz von Open-Weight-Modellen aus Reproduzierbarkeitsgründen; kostenfreie, nicht begrenzte Verfügbarkeit

Technical Setup**Implementation Method**

Vom ZDV der Universität zur Verfügung gestellte API

Runtime

Lokaler Cluster (Uniserver)

Model Configuration – Parameter Settings

- **Temperature:** 0.0
- **Top_p:** 1
- **Max tokens:** 5000

Rationale for Settings

Möglichst deterministische & reproduzierbare Ergebnisse mit niedriger Temperatur; Tokens ausreichend hoch, damit auch längere Rezensionen extrahiert werden können

Prompt / Input Design

Prompt Template

Verfügbar im GitHub Repository,

https://github.com/johannamauermann/Masterarbeit_Literaturbesprechungen

Prompt Development – Iterations

Zunächst Prompts mit weniger ausführlichen Anweisungen, dann auf auftretende Fehler (wie offenbar unklare Definitionen, was eine Literaturbesprechung ist) reagiert. Prompts wurden auch auf Deutsch getestet.

Testing Process

Kleineres Test-Datenset von 20 Beispielen, die verschiedene Herausforderungen des Datensets abbilden

Final Selection

Für beide Modelle anhand des Test-Datensets weitgehend zufriedenstellende Ergebnisse; systematisch auftretende Fehler schienen in dem Rahmen selten

Validation Methodology

Validation Method

Mix aus Vergleich mit Ground Truth (anhand Test Sample) und qualitativer Validierung

Acceptance Criteria

Keine vorab festgelegten Schwellenwerte: Nachvollziehbarkeit und hohe Übereinstimmung mit menschlicher Annotation waren das Ziel.

Error Handling

Manuelles Human-in-the-Loop-Review für als unsicher markierte Fälle; qualitative Fehleranalyse nach Fehlertyp (under extraction, over extraction, content mismatch, formatting error).

Random Seeds

-

Control Measures

Konsistente Temperatur = 0; selbe Prompts für beide Modelle

Verification Steps

1. Vergleich mit Ground Truth (Test Sample) [mit Fuzzy Matching];
2. Auf auftretende Fehler reagieren/diese im Close Reading feststellen

Performance Analysis

Metrics

Extraktion: Erfolgsscore, Recall, Precision (unter Einbeziehung von Partial Positives), differenziert nach Fehlertypen (under extraction, over extraction, formatting error, content mismatch [bei hoher Levenshtein Distanz innerhalb Textgrenzen]).

Anreicherung: mittlere kategorienweise Übereinstimmung Mensch–Modell (GPT: 81,8 %, Qwen: 83 %); dabei für Freitextfelder Fuzzy-Match-Schwelle von 0.8, bei der Werte noch als korrekt gelten.

Observed Issues

- GPT: systematische Untererfassung kurzer und werbeähnlicher Rezensionen (viele False Negatives).
- Qwen: hohe Anzahl False Positives durch Extraktion von Werbetexten, teilweise trotz korrekter interner Klassifikation (im <justification> Tag erklärt, dass es sich nicht um Rezension handelt, aber dann extrahiert).
- GPT: Schwierigkeiten bei der Erkennung von Ironie in Sentiment-Dimensionen.
- Qwen: Untererfassung inferierbarer Informationen, wie dem Geschlecht des Autors.
- Beide Modelle: Verlags-Extraktion fehleranfällig (Feld publisher daher von Analyse ausgeschlossen).

Workarounds

Human-in-the-Loop-Korrektur für alle 185 von den Modellen als unsicher markierten Fällen; häufiger auftretende Fehler bei der Analyse bedenken oder, wenn zu häufig, entsprechende Kategorien ausschließen (wie im Falle des Feldes publisher geschehen).

Unresolved Challenges

Aufgabe hat eine gewisse Ambiguität: Nicht immer unterscheidet sich z. B. Werbung für Bücher trennscharf von Rezensionen.

Resource Usage

Processing Time

1. Extraktion (1740 Texte): Qwen3 235B 14.950 Sekunden; GPT OSS 120B: 11.867 Sekunden
2. Rezensionen annotieren (633 Texte): Qwen3 235B: 4179 Sekunden; GPT OSS 120B: 7129 Sekunden

Memory Usage

Nur auf Uni-Seite ressourcenintensiv (API-Nutzung), hier besteht jedoch von außen kein genauer Einblick.

Total Cost

Keine direkten API-Kosten (lokale Servernutzung).

Ethical Considerations

Identified Biases

- Modellspezifische Fehlerprofile (GPT: False Negatives, Qwen: False Positives).
- Bei GPT: Ironische Formulierungen werden als positiv klassifiziert.
- Bei Qwen: Systematische Untererfassung des Geschlechts männlicher Autoren trotz eindeutiger grammatikalischer Marker.
- In einem Fall: Bekannter Autor (Heinrich Heine) statt tatsächlichem Autor (Wilhelm Heine) von beiden Modellen annotiert – Aktivierung von Trainingswissen statt Textlektüre.

Mitigation Steps

Human-in-the-Loop-Review für alle unsicheren Fälle (Übereinstimmung der Modelle untereinander bei diesen niedriger, was auf Schwierigkeiten hindeutet); qualitative Fehleranalyse und Ausschluss fehleranfälliger Felder (publisher) aus der Analyse.

Remaining Concerns

Modellbedingte Verzerrungen können nicht vollständig aufgelöst werden und sind als konstitutiver Bestandteil der erzeugten Daten zu verstehen.

Data Privacy

Verarbeitung ausschließlich auf lokaler Serverinfrastruktur der Universität; keine Übermittlung von Daten an externe API-Anbieter.

Compliance

Gemeinfreie Daten; Durch Verarbeitung auf Uni-Servern, verbleiben die Daten dort

Documentation

Code Repository

https://github.com/johannamauermann/Masterarbeit_Literaturbesprechungen